

PROYECTO 2

Minería de Datos Masivos: Grafos, Clustering, Recomendación y Análisis Avanzado

Prof. Heider Sanchez

Nota: El proyecto tiene como propósito **aplicar e implementar las técnicas vistas en clase** de manera práctica y comprensible. Para ello, deberán implementar las técnicas **sin recurrir a librerías externas**, de modo que el código refleje con claridad los principios y algoritmos que hemos estudiado. No se pretende **desarrollar un producto listo para producción**, sino **entender y aplicar las técnicas** de manera fundamentada. Los mejores trabajos serán aquellos que logren demostrar **profundidad de comprensión**, explicando cómo funciona cada técnica y mostrando resultados que evidencien su correcta aplicación.

OBJETIVO

Desarrollar un proyecto integral de minería de datos masivos aplicando técnicas avanzadas de análisis de grafos, ranking, clustering, reducción de dimensionalidad, sistemas de recomendación híbridos y minería de flujos de datos en tiempo real. Los estudiantes implementarán, evaluarán críticamente y reflexionarán sobre métodos en un dataset masivo real, construyendo soluciones coherentes que integren múltiples técnicas en pipelines funcionales.

RESULTADOS DE APRENDIZAJE

- R1. **Analizar y seleccionar** el método de minería de datos más apropiado en base a una necesidad de extracción de conocimiento.
- R2. **Implementar algoritmos de minería de datos** de manera estratégica, satisfaciendo requerimientos dados.
- R3. **Aplicar algoritmos de procesamiento y análisis de datos** para realizar tareas específicas de minería de datos (grafos, asociación, recomendación, clasificación).
- R4. **Construir soluciones basadas en minería de datos** para resolver problemas del mundo real (sistemas de recomendación y predicción con datasets masivos).

CONTEXTO Y DATASET

Los sistemas modernos de e-commerce, redes sociales y plataformas de opinión generan volúmenes masivos de datos con relaciones complejas. Este proyecto utiliza datasets de datos reales de millones de transacciones. El grupo debe elegir UN ÚNICO dataset y trabajar sobre él todo el proyecto.

Dataset	Escala	Características Principales
Yelp Open Dataset	6.9M reseñas, 150k negocios, 4.35 GB	Grafo de amigos usuarios Check-ins temporales Atributos geospaciales Ideal Para: Redes sociales, Flujos, Rankings
Amazon Product Reviews	233M reseñas, 15.5M productos, 58 GB	Grafo producto-producto Alta dimensionalidad textual 28 categorías de productos Ideal Para: Clustering, Recomendación, Dimensionalidad

PARTES DEL PROYECTO

PARTE I. PREPROCESAMIENTO Y ANÁLISIS EXPLORATORIO

Aplicar técnicas de limpieza y normalización en datos masivos. Construir representaciones apropiadas del dataset.

- Limpieza exhaustiva: valores faltantes, duplicados, inconsistencias, outliers. Justificar decisiones de tratamiento.
- Estadísticas descriptivas: distribuciones, correlaciones, análisis por segmentos. Gráficas exploratorias.
- Construcción de **grafo usuario-producto**. Calcular densidad, diámetro inicial.
- **Muestreo estratificado** si dataset > 50GB. Documentar representatividad del muestreo.

PARTE II. ANÁLISIS DE GRAFOS Y RANKING

Implementar algoritmos de análisis de enlaces y ranking. Construir rankings de influencia en redes masivas.

- **PageRank e HITS:**
 - Implementar PageRank iterativo para ranking de nodos (usuarios o productos más influyentes).
 - Aplicar HITS (Hubs and Authorities) para identificar nodos tipo "hub" (muchos outlinks) y "authority" (muchos inlinks).
 - Comparar rankings obtenidos. Interpretar: ¿Qué significa ser un "hub" o "authority" en el contexto del dataset?
- **Detección de Comunidades:**
 - Aplicar algoritmo de modularidad (Louvain) o Girvan-Newman para identificar grupos cohesivos en el grafo.
 - Caracterizar cada comunidad: tamaño, densidad interna, nodos clave, conexiones inter-comunidad. Interpretar: ¿qué representan las comunidades?

PARTE III. CLUSTERING (ELEGIR 2 DE 3)

Segmentar usuarios/productos en grupos para análisis estratégico.

- K-Means++: Mejor versión de K-Means para inicialización (elegir centroides distanciados). Utilizar principalmente para determinar k óptimo usando método del codo (intra-cluster sum of squares) y coeficiente de silueta. Analizar características dominantes de cada cluster.
- DBSCAN: Algoritmo basado en densidad (no requiere especificar k a priori). Determinar eps (radio de vecindario) y minPts (mínimo de puntos) óptimos usando k-distance plot. Detectar outliers automáticamente (puntos no asignados a clusters).
- CURE (Clustering Using Representatives): Algoritmo jerárquico aglomerativo que usa representantes de clusters. Maneja clusters no globulares mejor que K-Means. Evaluar complejidad temporal/espacial. Gráfica comparativa con DBSCAN en términos de silueta, purity, normalized mutual information.
- BFR (Bradley-Fayyad-Reina): es una extensión escalable de K-Means diseñada para grandes datasets que se procesan en bloques; divide los puntos en tres conjuntos: Discard Set (DS), Compression Set (CS) y Retained Set (RS); utiliza distancia de Mahalanobis para manejar la forma y dispersión de los clusters, lo que permite eficiencia en memoria y tiempo al trabajar con datos masivos.

PARTE IV. SISTEMAS DE RECOMENDACIÓN HÍBRIDOS

Construir sistemas de recomendación escalables. Integrar múltiples enfoques para mejorar precision y coverage.

- Filtrado Colaborativo (User-Based/Item-Based): Calcular similitud usuario-usuario o producto-producto (coseno, Pearson). Generar recomendaciones top-K usando k-NN ponderado. Análisis de cold-start problem (usuarios/items nuevos).

- Content-Based: Extraer features de contenido (TF-IDF de reseñas, atributos de productos). Computar similitud entre items en espacio de features. Recomendar items similares a los que el usuario interactuó previamente.
- Combinación Híbrida: Pesar/combinar predicciones de múltiples métodos (weighted average, stacking, learning-to-rank). Evaluación rigurosa: Precision@K, Recall@K, NDCG (ranking quality), RMSE, MAE (rating prediction). Comparativa con baseline (p.ej., recomendación aleatoria, top-popular items).

PARTE V. MINERÍA DE FLUJOS DE DATOS

Simulación de procesamiento de datos en tiempo real. Mantener estadísticas y patrones sobre flujos continuos con restricciones de memoria.

- Ventanas Deslizantes: Dividir stream en ventanas de tiempo (1h, 4h, 1 día). Calcular estadísticas (count, sum, average) dentro de cada ventana. Análisis temporal: tendencias de popularidad, patrones horarios, ciclos estacionales.
- Conteo Aproximado: Implementar algoritmos que procesan stream un elemento a la vez sin almacenar todos (Count-Min Sketch para frequency estimation). Demostrar garantías teóricas de error. Comparar con conteo exacto.
- El equipo debe aplicar una técnica adicional de data stream mining, justificando su aporte en función de la evidencia obtenida a partir de los datos.

PARTE VI. REDUCCIÓN DE DIMENSIONALIDAD

Aplicar técnicas de compresión y visualización. Extraer patrones latentes en datos de alta dimensión.

- PCA (Principal Component Analysis): Estandarizar features. Calcular matriz de covarianza y eigenvalores. Seleccionar componentes que expliquen 90%+ de varianza. Visualizar datos proyectados en 2D/3D. Interpretar: qué variables contribuyen a cada PC principal.
- SVD (Singular Value Decomposition): Aplicar a matriz TF-IDF de reseñas o matriz usuario-producto. Interpretar factores singulares como patrones latentes. Reconstrucción de datos: truncar a k dimensiones y evaluar error de reconstrucción. Comparar compresión lograda vs pérdida de información.

PARTE VII. ANÁLISIS CRÍTICO Y ÉTICO

- Comparar exactitud vs eficiencia de los métodos.
 - Escalabilidad: Análisis de complejidad computacional (tiempo, espacio) de cada algoritmo. Tradeoffs: exactitud vs eficiencia. ¿Qué técnicas escalan a datos aún más masivos?
- Reflexionar sobre implicancias éticas de la personalización.
 - Sesgos: Subrepresentación en datos (p.ej., usuarios de ciertos grupos menos representados). Reseñas falsas/spam. Cómo afectan a clustering, ranking, recomendaciones.
 - Equidad: ¿Recomendaciones/rankings favorecen injustamente a ciertos grupos? Diversidad vs relevancia. Impacto en pequeños negocios vs grandes cadenas.

ENTREGABLE Y RUBRICA

ENTREGABLES

1. Código fuente (GitHub): Módulos Python organizados (ejemplo: preprocessing.py, graphs.py, clustering.py, recommenders.py, streaming.py, dimensionality_reduction.py). Jupyter notebooks exploratorios. README completo con instrucciones, dependencias.
2. Reporte final (6-8 páginas): Introducción, metodología (justificación de técnicas elegidas), resultados con tablas/gráficas, análisis crítico, conclusiones, referencias bibliográficas.

3. Presentación (30 min): Resumen significativo, demo interactiva de resultados, conclusiones y lecciones aprendidas.

RÚBRICA DE EVALUACIÓN

Criterio	RA	Descripción	Puntos
Selección y Prep.	RA1, RA2	Dataset elegido y justificado, limpieza exhaustiva documentada, EDA con gráficas, grafos iniciales contruidos.	2
Análisis de Grafos	RA2	PageRank/HITS correctos, 3+ comunidades caracterizadas, interpretación clara de nodos influyentes y estructura.	4
Clustering	RA3	K-Means++, (DBSCAN, CURE o BFR), k óptimo con gráficas, silueta, comparativa métodos.	4
Recomendación	RA3	2 métodos integrados, hybrid system, evaluación Precision@K/RMSE/MAE/NDCG.	4
Flujos + Dim.	RA2, RA3	Ventanas deslizantes, Count-Min Sketch, otros.	3
Ética + Código + Reporte	RA4	Reflexión escalabilidad/sesgos/equidad, código limpio modular, reporte.	3
TOTAL			20

** Cualquier falla en la presentación o pregunta no respondida afectará directamente el puntaje final.*